Reporte del Proyecto 1 - Analítica de resultados Saber 11 (Cesar, Colombia)

Juan Camilo Medina – 202122966

Nicolás Salazar – 202124147

María Inés Velásquez – 20222432

¿Existen brechas significativas en el puntaje global entre colegios Oficiales y No Oficiales? 2

Detalle de pregunta 2

Análisis de datos 2

Hallazgos asociados 2

¿En qué medida influencia la educación familiar en el resultado general de las pruebas Saber11? 3

Detalle de pregunta 3

Análisis de datos 3

Hallazgos asociados 3

¿Existen diferencias en el desempeño de los estudiantes del Cesar en las pruebas Saber 11 según el calendario del colegio? 4

Detalle de pregunta 4

Análisis de datos: 4

Hallazgos asociados: 4

Pasos principales del rol de ingeniería de datos 5

Pasos principales del diseño y desarrollo del tablero de datos 6

Pasos principales del rol de despliegue y mantenimiento de datos 7

¿Existen brechas significativas en el puntaje global entre colegios Oficiales y No Oficiales?

Detalle de pregunta

La pregunta busca identificar si existen diferencias significativas entre los puntajes obtenidos en la prueba saber 11 de los Colegios Oficiales o Públicos y los Colegios No Oficiales o Privados. En caso de haber diferencias, lograr identificar que categoría presenta mejores resultados.

Análisis de datos

Se llevo a cabo un análisis con estadísticas descriptivas y gráficas para poder entender el comportamiento de los datos, e identificar si hay diferencias entre los dos conjuntos. Identificamos algunas estadísticas descriptivas. Luego, se llevó a cabo una comparación por la media del puntaje por "materia" para cada naturaleza de colegio. También, se llevaron a cabo test de Levene para comparar varianzas, el cual indicó varianzas diferentes, y las pruebas de t y Mann-Whitney U, que nos indicaron que efectivamente había diferencia significativa entre las medias de ambos tipos de colegio. Finalmente, se presentan las principales gráficas obtenidas.

Indicador-Tipo colegio	Oficial	No Oficial
Cantidad	63,075	14500
Media	239,65	257,20
Desv. Std.	41.53	59.22
Mediana	236	252
Min	18	0
Max	465	465
Q1	209	210
Q3	267	302

Tabla 1: estadísticas descriptivas naturaleza del colegio

En la OLS obtuvimos un intercepto de 239.65 y un coeficiente de 17.5 (con referencia Oficial). Aunque cabe destacar que en este modelo únicamente se considera la variable de naturaleza del colegio, posteriormente, en el modelo con más variables, estos valores cambiaran levemente (como es de esperarse). No obstante, a grandes rasgos los resultados son los mismos: "es mejor el puntaje promedio de los colegios No Oficiales que el de los colegios Oficiales".

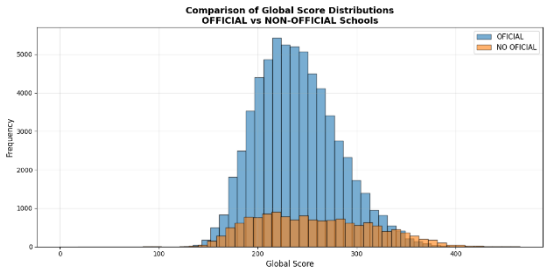

Ilustración 2: histogramas superpuestos, puntaje global según naturaleza del colegio

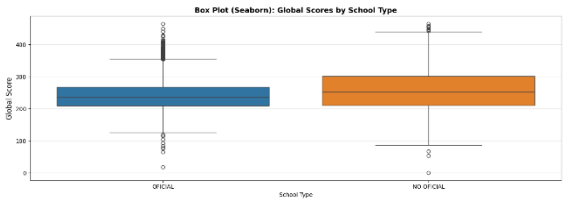

Ilustración 1: Diagramas de caja naturaleza del colegio

Hallazgos asociados

Podemos evidenciar que hay diferencias entre las medias de los dos colegios, siendo la de los colegios No Oficiales mayor, lo cual fue confirmado por las pruebas de hipótesis y una OLS como mencionado anteriormente. También, podemos ver que los colegios de carácter No Oficial presentan un mejor desempeño en las pruebas, no solo en carácter global, si no en general para cada materia. Cabe destacar que, la dispersión de los colegios Oficiales es menor, por lo cual sus resultados tenderán a estar más cercanos a la media de su conjunto.

¿En qué medida influencia la educación familiar en el resultado general de las pruebas Saber11?

Detalle de pregunta

Se busca analizar si existe relación entre el puntaje global de los estudiantes del Cesar y el nivel educativo de sus padres, evaluando si un mayor nivel de educación familiar se asocia con mejores resultados.

Se utilizará como variable dependiente el puntaje global (punt_global) y como variables independientes la educación de la madre (fami_educacionmadre) y la educación del padre (fami_educacionpadre).

Análisis de datos

Considerando las variables y el set de datos asignados se realizaron diferentes análisis descriptivos y visualizaciones.

fami_educacionmadre	count	mean	std	min	25%	50%	75%	max
Educación profesional completa	7946.0	272.868739	52.936613	134.0	234.00	271.0	311.0	458.0
Educación profesional incompleta	1465.0	267.978157	51.887550	143.0	229.00	266.0	305.0	465.0
Ninguno	2535.0	221.609467	38.487041	128.0	194.00	217.0	247.0	368.0
No Aplica	76.0	212.315789	42.960512	152.0	177.75	199.5	237.0	320.0
No sabe	1309.0	243.753247	52.034005	18.0	204.00	237.0	277.0	404.0
Postgrado	1078.0	300.668831	56.428464	131.0	261.00	304.0	342.0	438.0
Primaria completa	8562.0	229.138402	37.894574	0.0	202.00	226.0	253.0	408.0
Primaria incompleta	10821.0	227.140006	36.800324	65.0	200.00	224.0	251.0	410.0
Secundaria (Bachillerato) completa	20544.0	242.704780	42.395594	87.0	212.00	239.0	270.0	465.0
Secundaria (Bachillerato) incompleta	11152.0	236.145714	39.586279	68.0	207.00	233.0	261.0	449.0
Técnica o tecnológica completa	7702.0	258.823682	44.181848	133.0	227.00	257.0	290.0	432.0
Técnica o tecnológica incompleta	1860.0	249.686022	44.982147	53.0	215.00	247.0	280.0	424.0

Ilustración 3 Medidas descriptivas educación madre

fami_educacionpadre	count	mean	std	min	25%	50%	75%	max
Educación profesional completa	7373.0	272.323478	51.916004	133.0	235.00	271.0	309.0	458.0
Educación profesional incompleta	1220.0	267.369672	50.665629	139.0	229.75	266.0	305.0	431.0
Ninguno	4275.0	224.400000	38.441077	128.0	196.00	220.0	249.0	383.0
No Aplica	274.0	240.897810	54.095531	138.0	198.00	237.0	277.0	391.0
No sabe	2992.0	249.074866	49.044338	18.0	212.00	245.0	281.0	427.0
Postgrado	1018.0	304.245580	57.118953	151.0	265.00	309.0	345.0	465.0
Primaria completa	8716.0	230.611634	38.178087	0.0	203.00	227.0	255.0	408.0
Primaria incompleta	13101.0	230.505534	37.794849	65.0	203.00	227.0	255.0	465.0
Secundaria (Bachillerato) completa	19005.0	244.640989	43.476779	87.0	213.00	241.0	273.0	447.0
Secundaria (Bachillerato) incompleta	10243.0	236.523772	40.707000	119.0	207.00	233.0	262.0	449.0
Técnica o tecnológica completa	5393.0	260.445763	45.547124	53.0	228.00	258.0	292.0	431.0
Técnica o tecnológica incompleta	1474.0	247.381275	44.256272	131.0	215.00	245.0	275.0	398.0

Ilustración 4 Medidas descriptivas educación padre

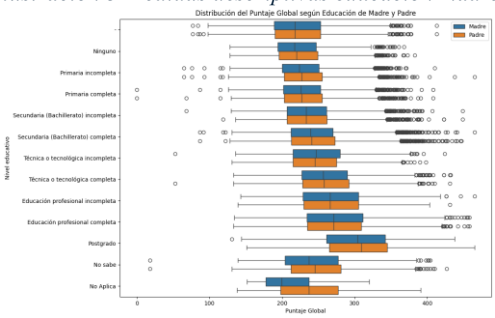

Ilustración 5 Puntaje global según educación de los padres

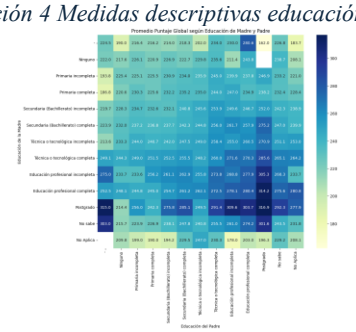

Ilustración 6 Promedio del puntaje global según la educación de los padres

Se calcularon los promedios del puntaje global según el nivel educativo de la madre y del padre, y se construyeron visualizaciones como un mapa de calor para observar la combinación de ambos niveles educativos y boxplots para analizar la distribución, mediana y dispersión de los puntajes por grupo. Esto permitió comparar objetivamente las diferencias en rendimiento entre los distintos niveles educativos familiares.

Hallazgos asociados

Se identifica una relación positiva entre el nivel educativo de los padres y el puntaje global: a mayor nivel de formación (especialmente profesional y posgrado), mayores son los promedios obtenidos por los estudiantes. La tendencia es consistente tanto para madre como para padre, lo que sugiere que un mayor capital educativo en el hogar se asocia con mejores resultados académicos.

¿Existen diferencias en el desempeño de los estudiantes del Cesar en las pruebas Saber 11 según el calendario del colegio?

Detalle de pregunta

Se busca analizar si el puntaje global de los estudiantes del departamento del Cesar difiere según el calendario académico del colegio (A o B), evaluando si pertenecer a un calendario distinto se asocia con diferencias sistemáticas en el desempeño en las pruebas Saber 11. Se utiliza como variable dependiente el puntaje global (punt_global) y como variable explicativa el calendario del colegio (cole_calendario), tomando como referencia el calendario A.

Análisis de datos:

Se realizó un análisis gráfico junto con estadísticas descriptivas de interés:

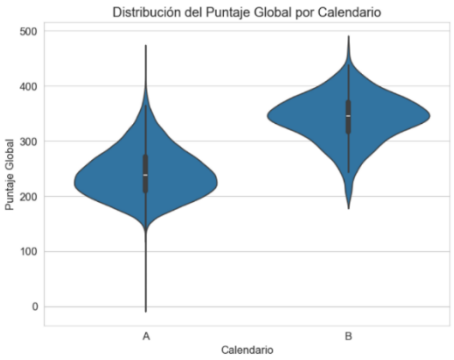

Media puntaje global calendario A: 242.46

Media puntaje global calendario B: 341.40

Desviación std. puntaje global calendario A: 45.38

Desviación std. puntaje global calendario B: 42.91

Diferencia de Medias (A-B): -98.65

Para evaluar formalmente la diferencia se realizó una prueba de i) igualdad de varianzas, para decidir el estadístico de prueba de ii) diferencia de medias. Como se rechazó la hipótesis de igualdad de varianzas, para la diferencia de medias se optó por un estadístico *t-Welch*, dado que es robusto ante heterocedasticidad.

Bajo cualquier nivel de significancia, se rechaza la hipótesis de igualdad de medias, por lo que se puede determinar que existen diferencias estadísticamente significativas entre los calendarios. En particular, la media del puntaje global para colegios calendario B es mayor.

Ahora bien, para evaluar la magnitud de esta diferencia, se regresó el puntaje global con el calendario, controlando por la naturaleza del colegio, la jornada, el área de ubicación y el nivel de escolaridad de los padres.

Tomando como referencia el calendario A, se obtuvieron los siguientes resultados para el coeficiente de interés:

$$\gamma_{calendarioB} = 41.23, \sigma_{\gamma_{calendarioB}} = 2.38, IC_{95\%} = [36.56, 45.91], efecto\ significativo$$

Mediante el coeficiente estimado, se determina que manteniendo constantes las demás variables del modelo, los estudiantes del calendario B obtienen en promedio 41.2 puntos más que los estudiantes del calendario A. Este efecto es estadísticamente significativo (p-value<0.001)

Hallazgos asociados:

Se identifican diferencias estadísticamente significativas en el desempeño según el calendario del colegio. Los estudiantes del calendario B presentan puntajes promedio superiores, y a pesar de que la

diferencia es amplia, esta se reduce al controlar por las variables mencionadas de la regresión, manteniéndose aún significativa. Esto indica que el calendario académico está asociado con el rendimiento en el puntaje global, aunque una parte del efecto podría estar influenciado por factores como el entorno escolar y socioeconómico.

Pasos principales del rol de ingeniería de datos

Responsable: Nicolás Salazar

Los principales pasos para el rol de ingeniería de datos fueron la extracción y limpieza de datos. Puntualmente, para la extracción de datos, se ingresó a la página con la información de los resultados de las pruebas saber 11 y se descargó el archivo .csv. Luego, se crearon las instancias de S3 en AWS para poder tener un entry y exit bucket de los datos, y se cargó el csv al entry bucket. Siguiendo, se creó en Athena un nuevo workgroup para el proyecto, seleccionando Athena SQL como analytics engine, y con el exit bucket como location of the query result. Posteriormente, se utilizo Glue, para dejar nuestro S3-Entry Bucket como fuente de datos, y, ligado a esto, se creo un crawler (también con Glue), para que extrajera los datos del CSV original, y los convirtiera en una tabla para facilitar su extracción. Con esto, se corrió el crawler el cual creo su respectiva tabla 'icfes_data', a la cual le tuvimos que ajustar su schema, por medio de la modificación del archivo .json que se puede encontrar en el repositorio, la idea era dejar todos los datos como string, con la excepción de los puntajes que dejamos de tipo double, de esta manera, evitábamos problemas cómo con códigos que empezaran en 0 y fueran convertidos a número, entre otros. Además, editamos la librería de serialización (pasamos a org.apache.hadoop.hive.serde2.OpenCSVSerde), con el fin de quitar los campos que se encontraban entre comillas "", y le agregamos a la tabla la propiedad de que le asignara null a los campos con datos inválidos (e.g. NaN). Con esto listo, volvimos a Athena, para realizar las consultas de SQL. Puntualmente, quitamos duplicados utilizando la palabra reservada distinct, seleccionamos únicamente las columnas que eran de interés para nuestras preguntas de negocio (periodo, ubicación colegio, calendario colegio, naturaleza colegio, nivel educativo de los padres, puntajes individuales y globales, etc), y claramente filtramos la tabla para quedarnos únicamente con los datos correspondientes al departamento del Cesar. Finalmente, se descargó el CSV resultante de la consulta para su posterior limpieza, que contaba con aproximadamente 152,000 filas.

Para la limpieza de datos se guardó el archivo CSV con formato UTF-8 con BOM para poderlo visualizar de forma preliminar en Excel. Luego, fue cargado en un cuaderno de Jupyter con pandas. No había necesidad de lidiar con NaN ni duplicados, pues ya habían sido corregidos en la extracción desde Athena, sin embargo, era necesario revisar los valores nulos, especialmente, en las columnas de puntajes, pues sobre estas se iban a realizar operaciones estadísticas posteriormente en el proyecto. De esta manera, se revisaron las filas con valores nulos en puntaje global, que correspondían aproximadamente al 38% del data set previo, antes de proceder con el manejo de estas, queríamos ver a que datos correspondían y pudimos ver que puntualmente correspondían a los datos de los periodos desde el 20101 hasta el 20141. Con esto, se tomó la decisión de remover estos datos del Data Frame, y llevar a cabo nuestras preguntas de negocio desde el periodo 20142 en adelante (hasta el periodo 20224). Finalmente, se revisó la forma (77575, 17), las columnas y la descripción del Data Frame para posteriormente exportar el CSV con los datos limpios y filtrados.

Pasos principales del diseño y desarrollo del tablero de datos

Responsable: Juan Camilo Medina

El dashboard fue desarrollado en Python utilizando Dash y Plotly, a partir de la base depurada de resultados de las pruebas Saber 11 para el Departamento del Cesar (resultado del procesi de limpieza y alistamiento de datos). En primer lugar, se realizó la carga y organización de la información, de tal forma que, variables categóricas como naturaleza del colegio (oficial, no oficial), calendario académico y nivel educativo de los padres, tuvieran un orden para facilitar análisis y visualizaciones siguientes.

Posteriormente, se incorporó el modelo estadístico (regresión OLS) con el fin de estimar el efecto de distintos factores sobre el puntaje global. Para el tablero, se obtuvieron coeficientes, niveles de significancia e intervalos de confianza que sirven como base para diferentes formas de visualización. Mediante callbacks, se puede escoger la forma en la que se observan los resultados del modelo; entre estos:

- Forest plots: Donde se presentan los coeficientes estimados, en forma de boxplots horizontales que representan sus intervalos de confianza
- Tablas estadísticas: Con los resultados de los coeficientes y su significancia individual
- Gráficos de distribución (violín y boxplots)
- Comparaciones y tarjetas de hallazgos clave

La estructura del Dash fue organizada en diferentes tabs; resumen general, naturaleza del colegio, calendario académico e influencia de la educación familiar. Finalmente, se trabajó en la capa de presentación mediante CSS personalizado, mejorando la estética del tablero, considerando el público objetivo.

De igual forma, se diseñaron tarjetas con métricas, se incorporó el logo del Ministerio de Educación y elementos visuales en el encabezado, con el objetivo de hacer el Dashboard más amigable.

Pasos principales del rol de despliegue y mantenimiento de datos

Responsable: María Inés Velásquez

Para realizar el despliegue y el mantenimiento de datos del tablero, se realizaron dos cosas principalmente: se creó y configuró una instancia en AWS y despues se subieron y desplegaron los archivos.

Se creó una instancia con las siguientes características:

- Nombre: Cesar
- Sistema operativo: Linux
- Tipo de máquina: t3.small

Inicialmente se probaron máquinas de menor capacidad como t3.micro, pero el tablero se demoraba mucho en cargar. Por ello, se escogió una máquina con mayor memoria y que fuera compatible con el plan educativo.

Durante la creación de la máquina se generó un par de llaves llamado "DeptoCesar.pem", que permitió conectar la máquina y subir los archivos posteriormente.

Se estableció una conexión con la maquina por medio de la terminal configurando el entorno e instalando todas las librerías necesarias para el funcionamiento del tablero como: pandas, dash y statsmodels.

Considerando que el tablero necesita acceso al archivo .csv para cargar los datos y mostrarlos, se subieron los siguientes elementos a la instancia:

- filtered_icfes_data.csv
- app.py
- assets (una carpeta con los componentes de estilo como fuentes y elementos visuales)

Para cargar la carpeta se usó el comando:

```
scp -i DeptoCesar.pem -r assets ec2-user@IP:/home/ec2-user
```

Despues, se modificó la ruta de acceso a los datos en el Dash y se configuró el parámetro de host para ejecutar el tablero correctamente.

Se actualizaron las reglas de entrada en los grupos de seguridad de AWS para permitir el tráfico por el puerto 8050, que es donde se despliega el tablero.

Finalmente, se ejecutó el tablero en la instancia y se verificó que funcionara correctamente, quedando disponible para el acceso y análisis de datos.