ANALÍTICA COMPUTACIONAL PARA LA TOMA DE DECISIONES

ANÁLISIS PRUEBAS SABER 11: CESAR

María Inés Velásquez, Nicolás Salazar, Juan Camilo Medina

AGENDA

1. Preguntas de negocio
2. Limpieza y alistamiento de datos
3. Exploración y Análisis de Datos
4. Despliegue en la nube
5. Tablero → Demostración

Preguntas de Negocio

01 ¿Existen brechas significativas en el puntaje global entre colegios oficiales y no oficiales?

02 ¿En qué medida influencia la educación familiar en el resultado general de las pruebas Saber11?

03 ¿Existen diferencias en el desempeño de los estudiantes del Cesar en las pruebas Saber 11 según el calendario del colegio?

Limpieza y Alistamiento de Datos

Extracción y arquitectura:

- Descarga del archivo oficial *.csv*
- Creación en AWS: S3 Entry Bucket (datos crudos), S3 Exit Bucket (resultados de consultas)
- Creación de Workgroup en Athena
- Configuración de Glue: Definición del Entry Bucket como fuente, creación del Crawler
- Generación de la tabla

Filtrado y Selección de Variables:

Mediante consultas en SQL:

- Eliminación de duplicados con *SELECT DISTINCT*
- Selección de variables relevantes para responder las preguntas de negocio
- Filtrado únicamente el departamento del Cesar

→ Obtención de CSV descargado con aproximadamente 152,000 observaciones

Validación:

- Archivo guardado en formato UTF-8 con BOM
- Cargado en Jupyter Notebook con pandas
- No se detectaron duplicados adicionales
- Se verificaron valores nulos en porcentajes

Análisis de datos faltantes:

- Se presentaron 47,610 valores nulos → 38.03% del dataset
- Al agrupar por periodo se encontró que correspondían a periodos 2010-1 - 2014-1

→ Eliminación de dichos periodos

Dataset final:

Se eliminaron observaciones con puntaje global = *null*

(observaciones: 75,575; variables: 17)

Variables categóricas

- Ubicación del colegio: rural, urbano
- Calendario del colegio: A, B
- Jornada del colegio: mañana, tarde, completa, entre otros
- Naturaleza del colegio: oficial, no oficial
- Nivel de escolaridad de los padres

Variables continuas

- Puntajes individuales: matemáticas, sociales ciudadanas, ciencias naturales, lectura crítica, inglés
- Puntaje global (variable de interés)

+consecutivo de estudiante, código y nombre del colegio

Exploración y Análisis de Datos

Análisis descriptivo de puntajes individuales

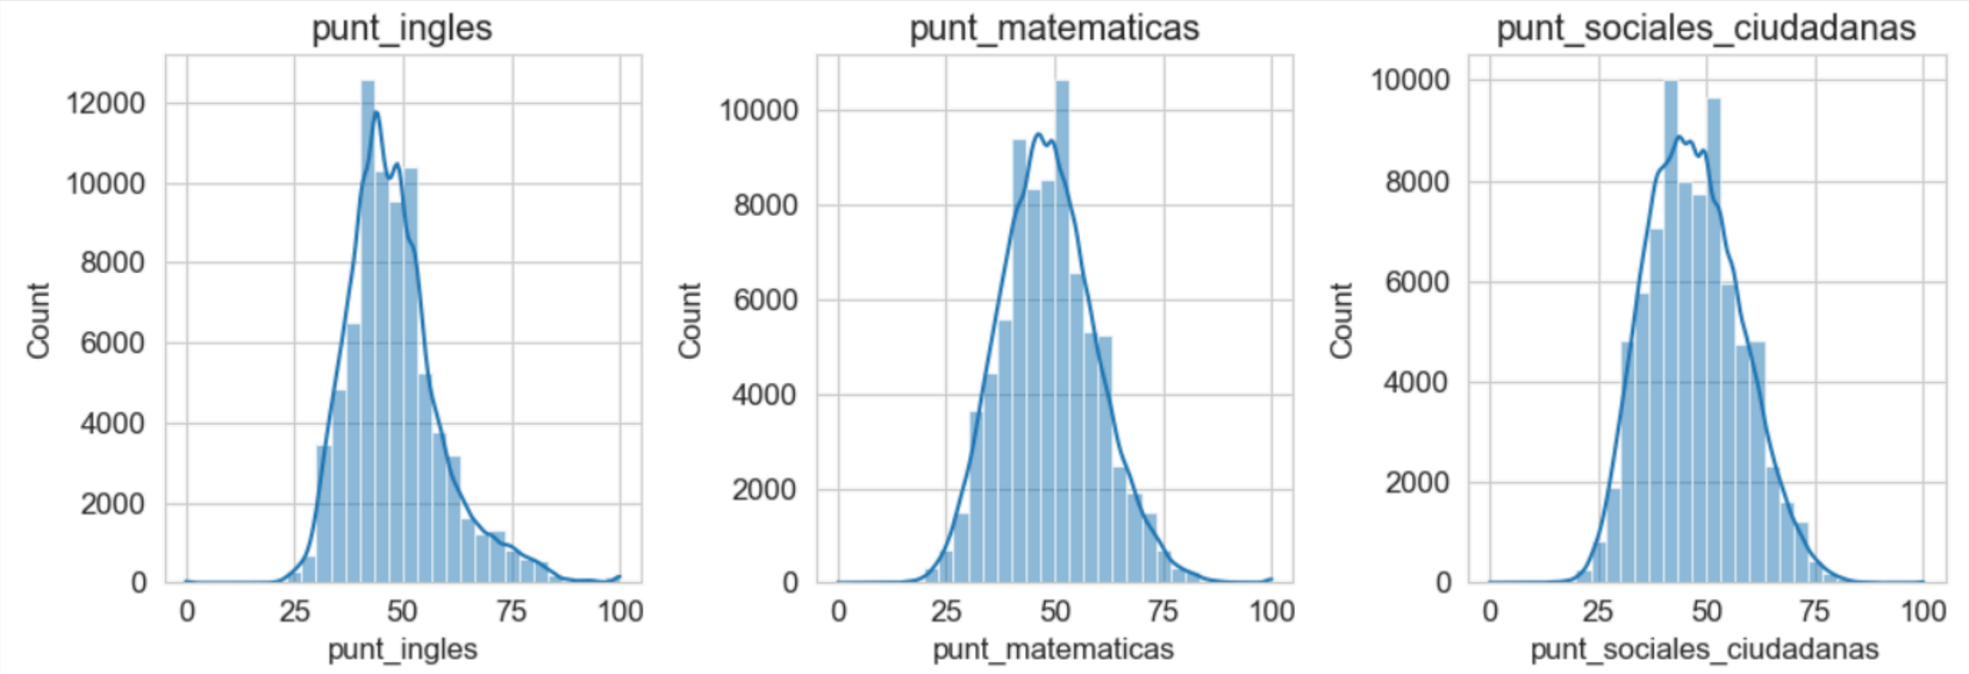

Media:	47.97	48.63	48.63
Desviación:	10.96	11.13	11.13
Mediana:	47	48	48

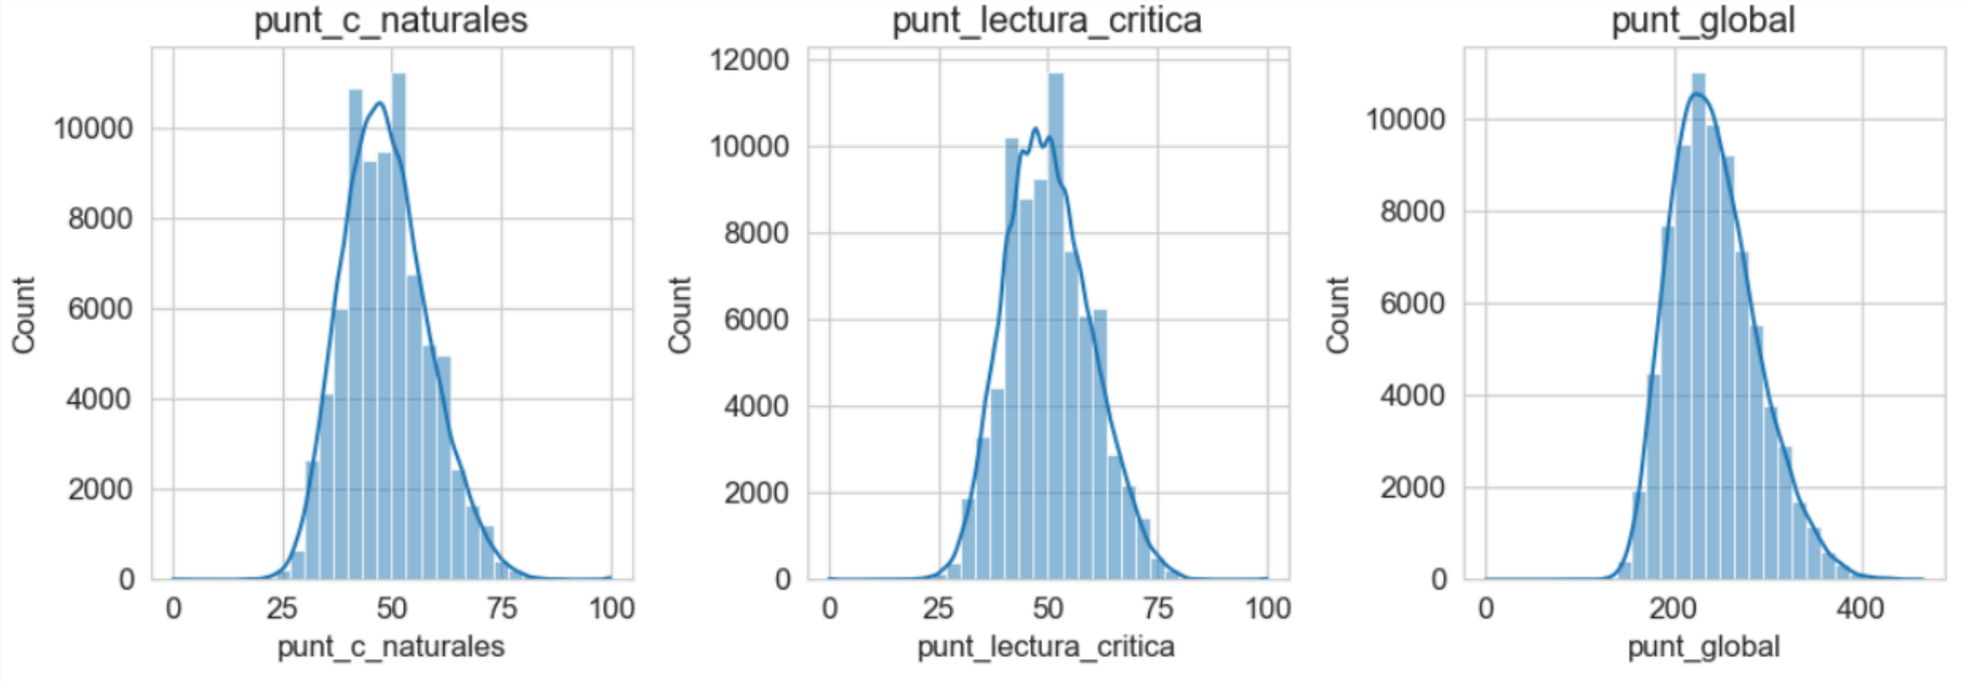

Media:	47.71	50.09	242.93
Desviación:	9.89	9.79	45.88
Mediana:	48	50	238

Relaciones Bivariadas entre puntajes individuales y global

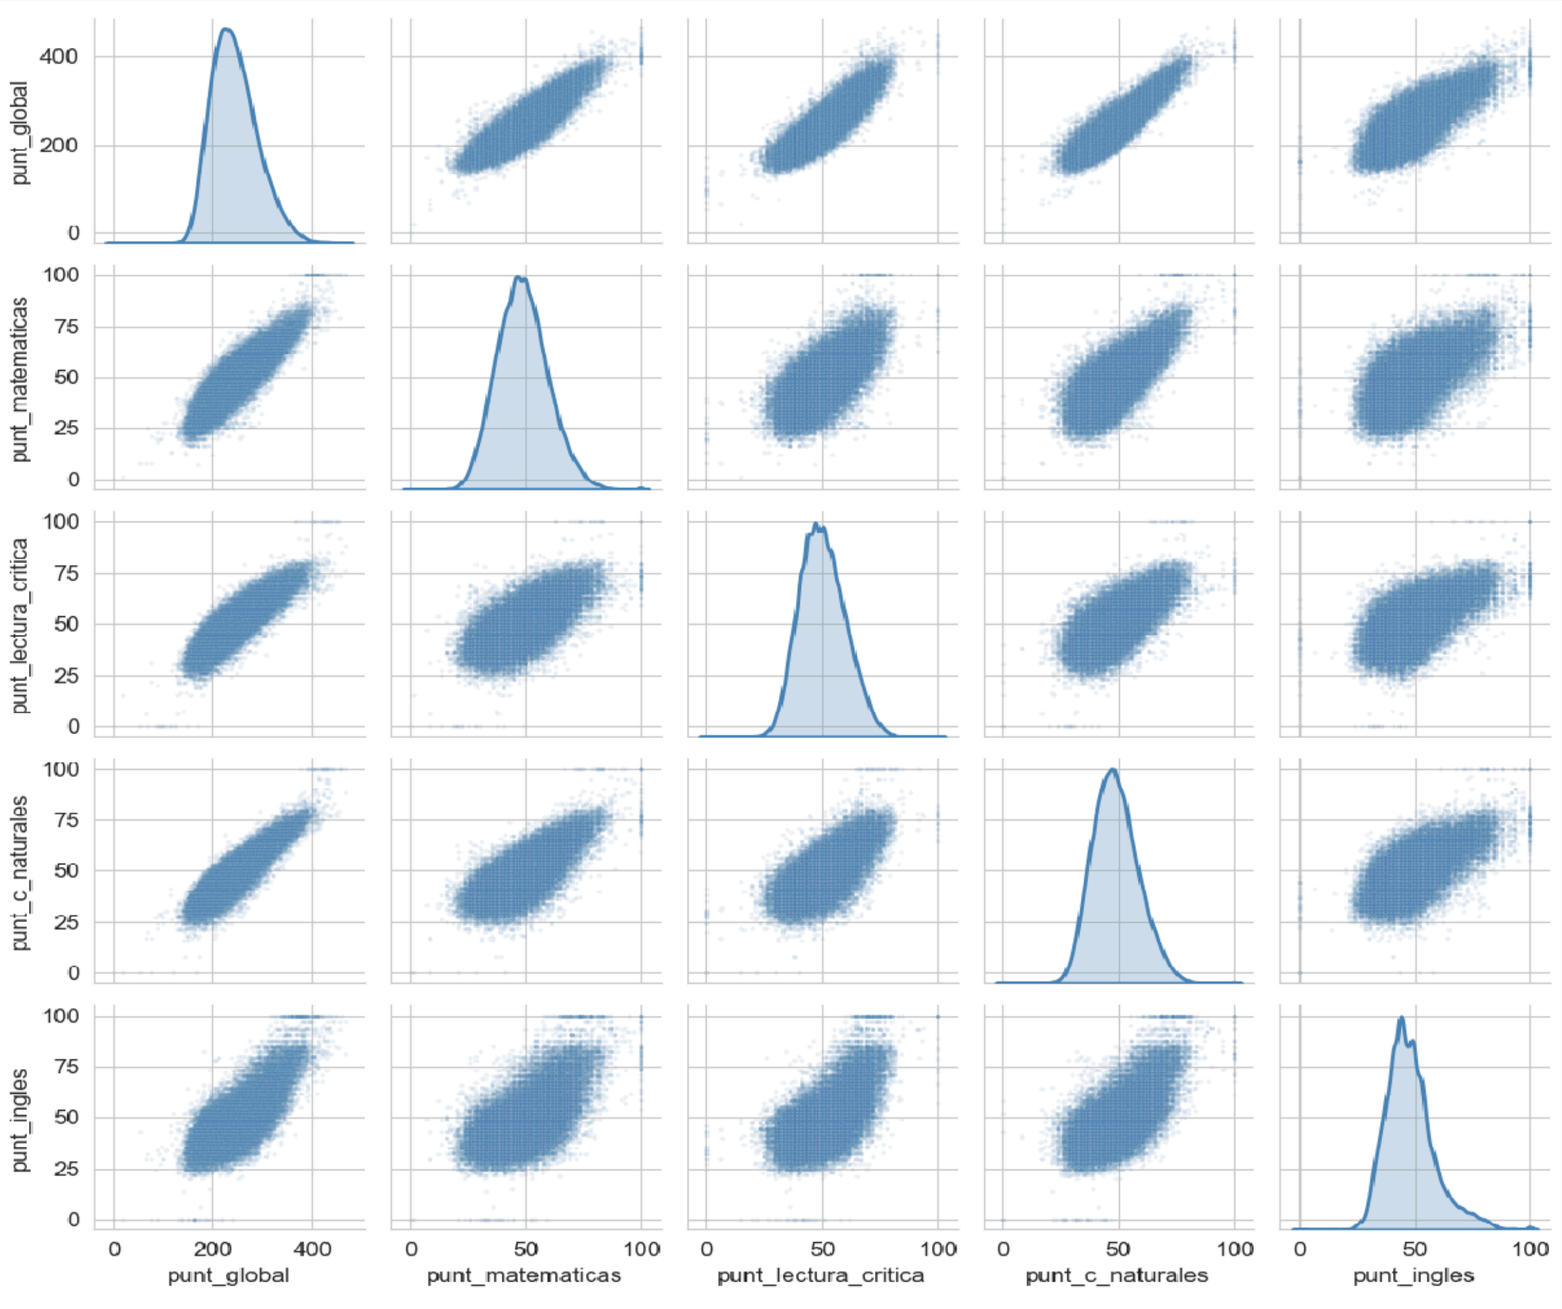

Correlaciones de variables continuas

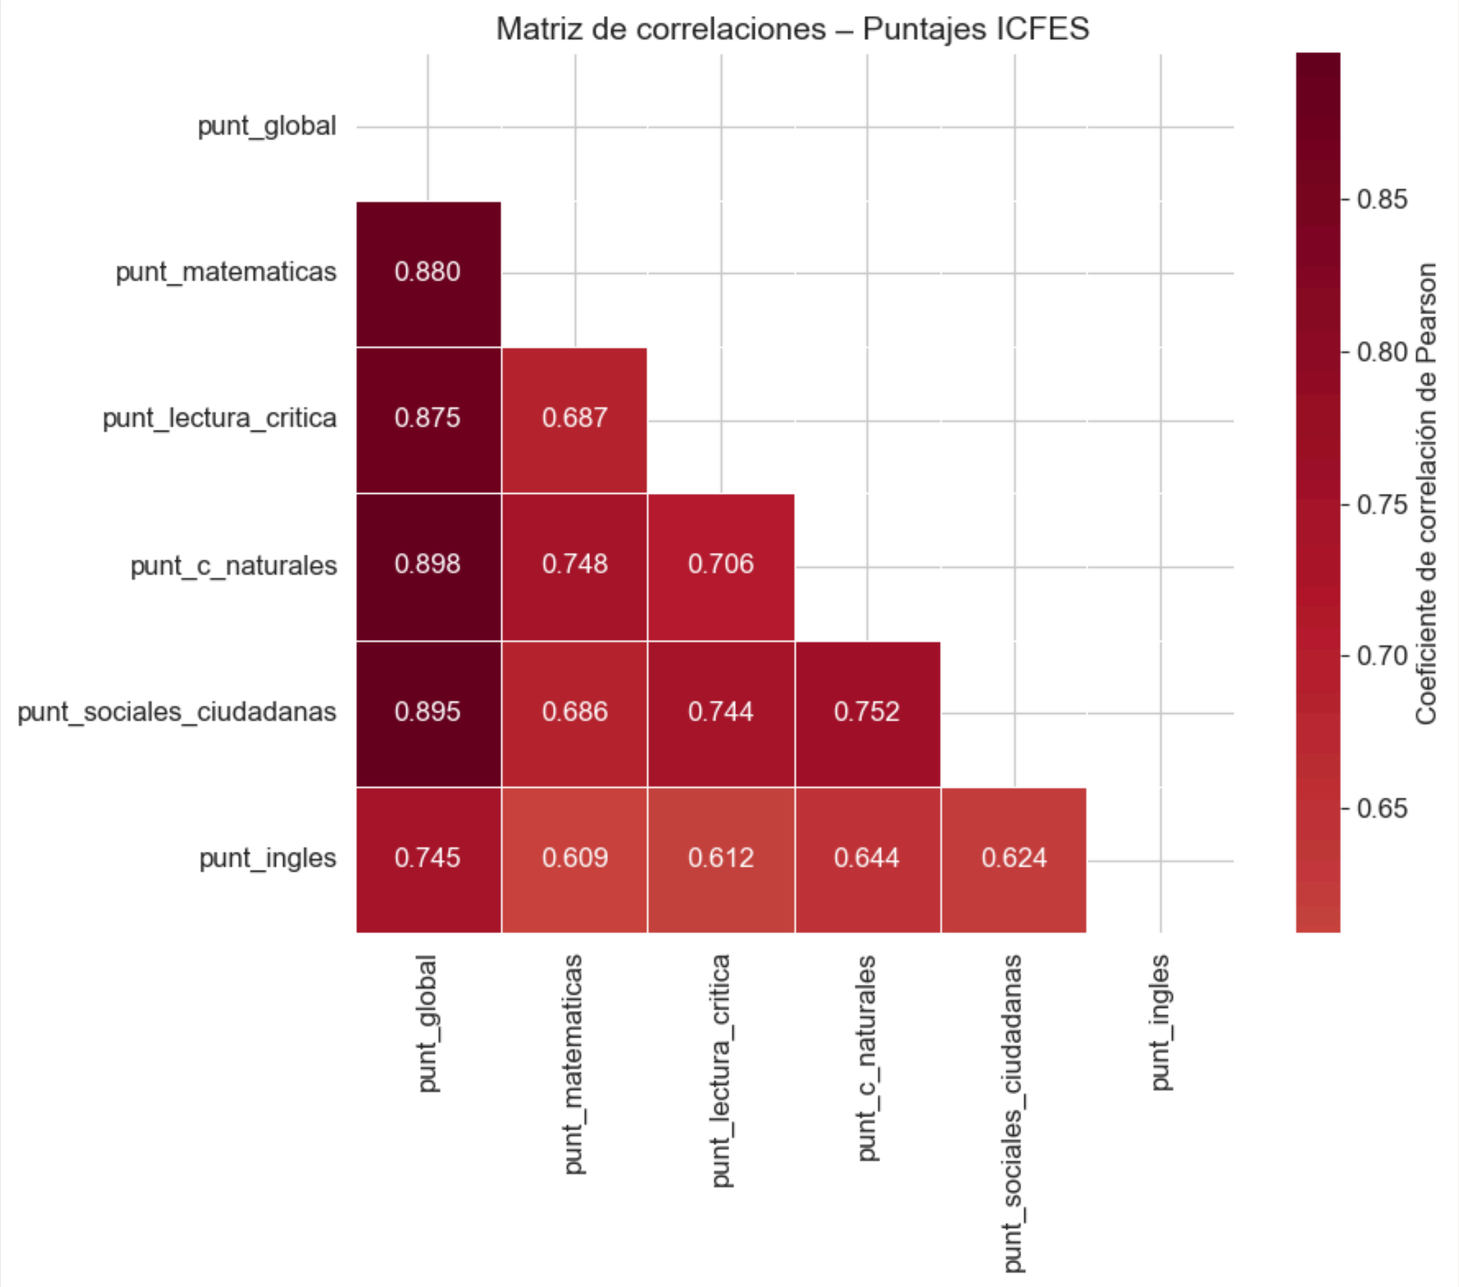

Análisis Categóricas vs. Puntaje Global

→ Por medio de diagramas de violín, se detectaron indicios de diferencias entre clases con respecto a la variable de interés

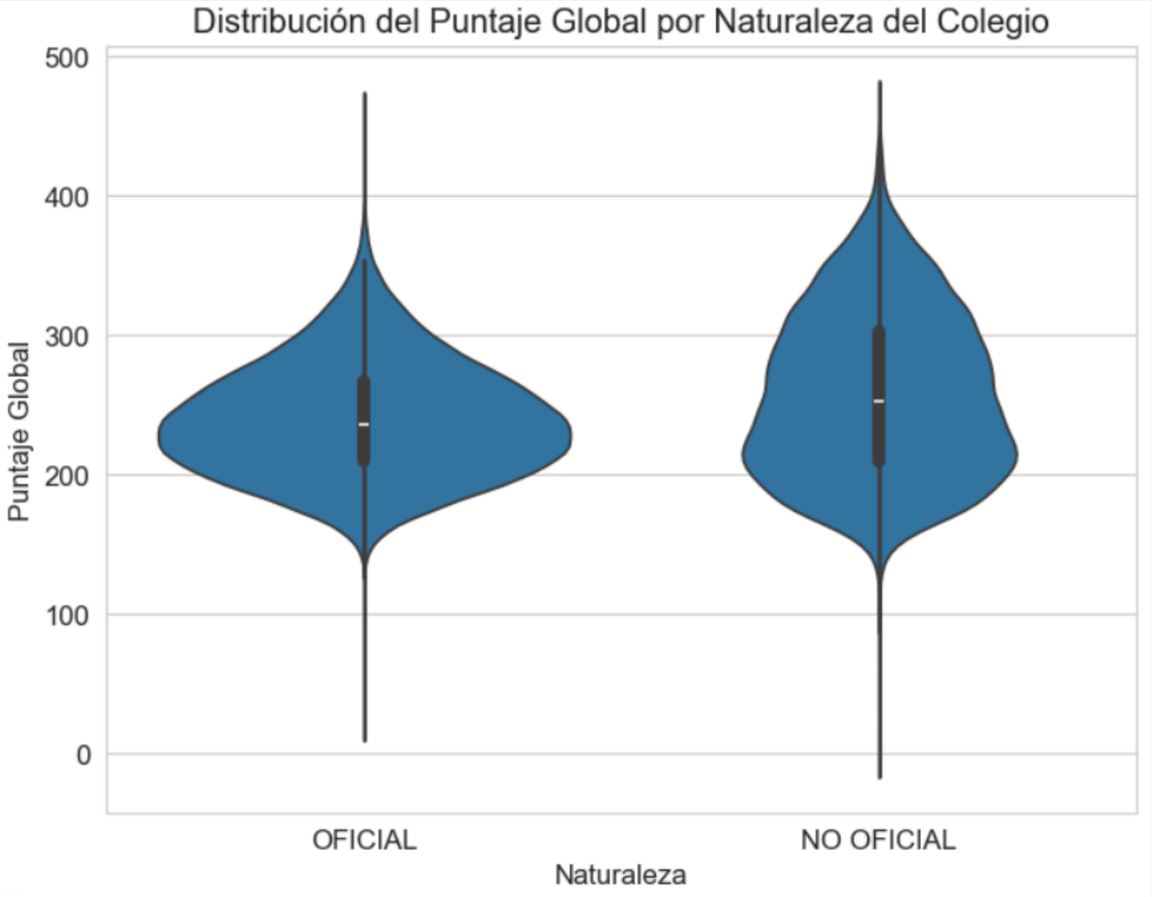

→ Mediante pruebas estadísticas se confirmaron dichos indicios, para categóricas con dos clases.

$$H_0: \mu_{global,oficial} - \mu_{global,no\ oficial} = 0$$
$$H_1: \mu_{global,oficial} - \mu_{global,no\ oficial} \neq 0$$

$$Estadístico\ t - Welch\ para\ heterocedasticidad$$

↓ confirmado por Levene-test

↓ Existen diferencias estadísticas significativas entre la media del puntaje global de colegios oficicales y no oficiales.
Colegios no oficiales presentan una media superior

Pregunta de negocio 1

Diferencia entre calendarios

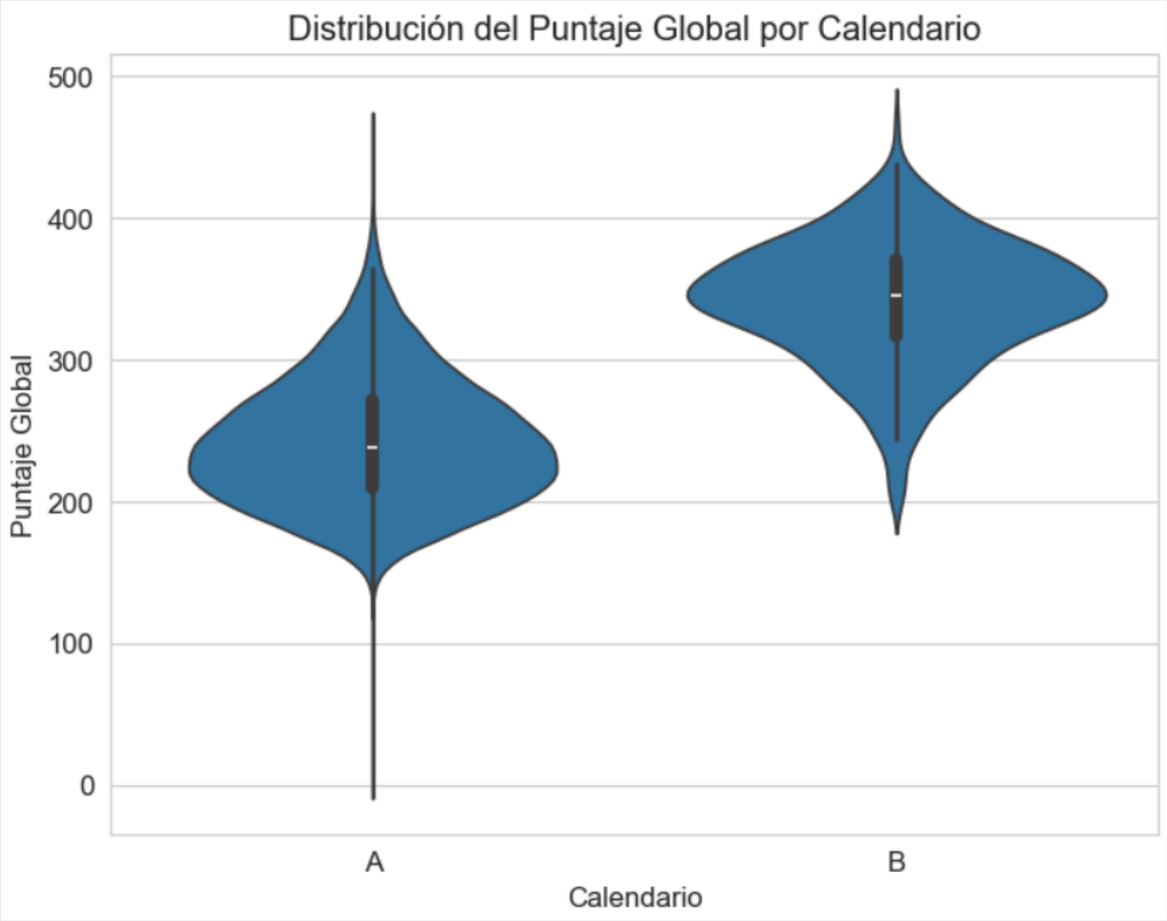

$$H_0: \mu_{global,A} - \mu_{global,B} = 0$$
$$H_1: \mu_{global,A} - \mu_{global,B} \neq 0$$

$$Estadístico\ t - Welch\ para\ heterocedasticidad$$

Válido aplicar prueba t considerando TLC

Existen diferencias estadísticas significativas entre la media del puntaje global de colegios calendario A y B.
Colegios calendario B presentan una media superior
→ Resultado consistente bajo relación entre naturaleza y calendario

Naturaleza / Calendario	No oficial	Oficial
A	18.30%	81.70%
B	100%	0%

Pregunta de negocio 3

Análisis de Nivel de Escolaridad de Padres

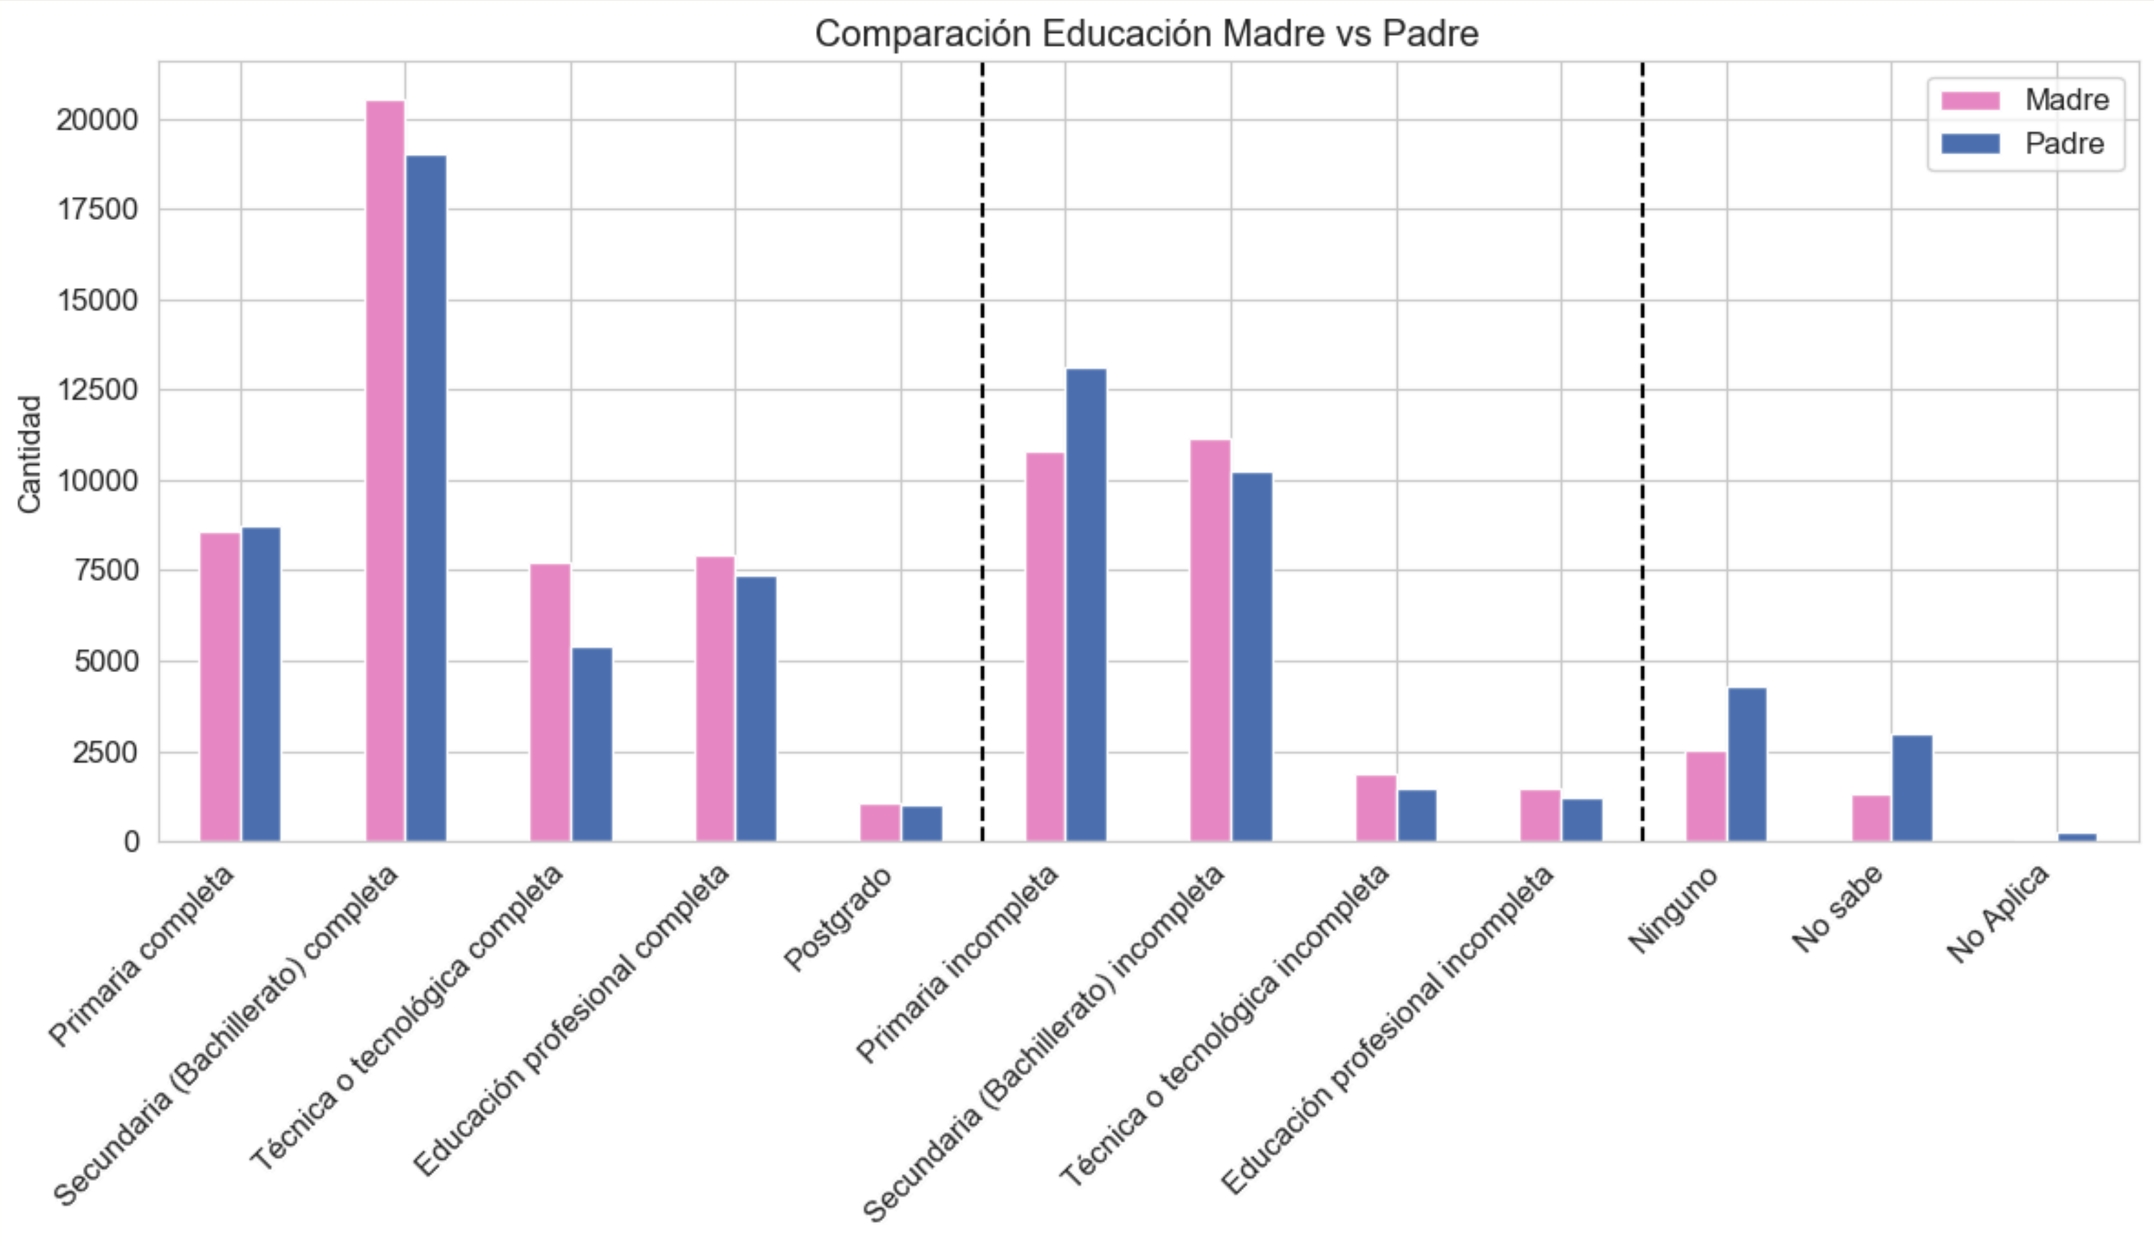

Modelo de Regresión

Con el fin de observar las relaciones entre categóricas y puntaje global

$$punt_global = f(cole_naturaleza, cole_calendario, cole_area_ubicacion, cole_jornada, fami_educacion_madre, fami_educacion_padre)$$

Desempeño global del modelo:

N= 74,964
glR= 30
glE= 74,933

R^2 =0.241
El modelo explica aproximadamente el 24% de la variablilidad muestral del puntaje global

$$H_0: \gamma_1 = \gamma_2 = \cdots = \gamma_6$$
$$H_1: \exists\, \gamma_i \neq 0$$

$\longrightarrow$ Estadístico F, con errores robustos

El modelo es globalmente significativo; las variables incluidas están asociadas con el desempeño en las pruebas Saber11

Análisis de Coeficientes

- **Naturaleza del colegio: (Referencia Oficial)**

$$\underset{cole_naturaleza_{no\ oficial}}{\gamma_1} = 9.59 \rightarrow IC_{95\%} = [8.40, 10.72]$$

Estudiar en un colegio no oficial se asocia con un aumento promedio de 9.6 puntos en el puntaje global, *ceteris paribus*. Efecto individualmente significativo.

- **Calendario del colegio: (Referencia A)**

$$\underset{cole_calendario_B}{\gamma_2} = 41.23 \rightarrow IC_{95\%} = [36.56, 45.91]$$

Los estudiantes calendario B obtienen en promedio 41.2 puntos más que calendario A, *ceteris paribus*. Efecto individualmente significativo.

Análisis de Coeficientes

- **Nivel de escolaridad de padres, resultados principales:**

Madre

$$\gamma_{3_{madre,postgrado}} = 26.74 \rightarrow IC_{95\%} = [23.52, 29.95]$$

$$\gamma_{4_{madre,profesional_completa}} = 13.04 \rightarrow IC_{95\%} = [11.74, 14.35]$$

$$\gamma_{5_{madre,primaria_incompleta}} = -6.36 \rightarrow IC_{95\%} = [-7.33, -5.38]$$

Padre

$$\gamma_{6_{padre,postgrado}} = 24.52 \rightarrow IC_{95\%} = [21.21, 27.83]$$

$$\gamma_{7_{padre,profesional_completa}} = 9.63 \rightarrow IC_{95\%} = [8.28, 10.97]$$

$$\gamma_{8_{padre,primaria_incompleta}} = -4.09 \rightarrow IC_{95\%} = [-5.04, -3.13]$$

Tablero → Demostración:

Versión Móvil

Versión Web

Despliegue en la Nube

- Creación de la instancia en AWS (Linux, t3.small)
- Generación de la llave DeptoCesar.pem para conexión
- Configuración del entorno e instalaron librerías (pandas, dash, statsmodels)
- Transferencia de archivos: app.py, filtered_icfes_data.csv y carpeta assets
- Ajuste de ruta de datos y el host en la aplicación
- Habilitación del puerto 8050 en los grupos de seguridad
- Ejecución y verificación del correcto funcionamiento del tablero

GRACIAS

Maria Inés Velásquez, Nicolás Salazar, Juan Camilo Medina